

# LARGE SCALE GAN TRAINING FOR HIGH FIDELITY NATURAL IMAGE SYNTHESIS

Mikhailov Nikita, 161

Higher School of Economics

30.01.2020


# State-of-the-art GAN

Self-Attention  
Generative  
Adversarial Networks  
(SA-GAN)

Inception Score=52.52 (больше – лучше)  
Frechet Inception Distance=18.65 (меньше – лучше)

# Что хочется улучшить?

- Метрики
- Разрешение изображений
- Качество генерирования мелких деталей



Лицо человека

- Увеличение BatchSize
- Увеличение ширины сети

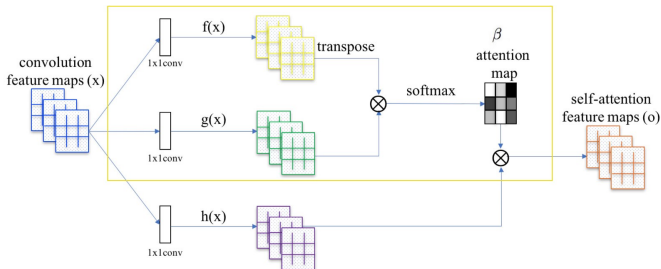
Batch	Ch.	Param (M)	Shared	Skip-z	Ortho.	Itr $\times 10^3$	FID	IS
256	64	81.5	SA-GAN Baseline			1000	18.65	52.52
512	64	81.5	✗	✗	✗	1000	15.30	58.77( $\pm 1.18$ )
1024	64	81.5	✗	✗	✗	1000	14.88	63.03( $\pm 1.42$ )
2048	64	81.5	✗	✗	✗	732	12.39	76.85( $\pm 3.83$ )
2048	96	173.5	✗	✗	✗	295( $\pm 18$ )	9.54( $\pm 0.62$ )	92.98( $\pm 4.27$ )

# SA-GAN

- self-attention для изображений
- conditional batch normalization
- Информация о классе в D и G
- Hinge-loss в GAN

# Self-Attention для изображений

- $f : [C, HW], g : [C, HW], h : [C_0, HW]$
- $m = f^T \cdot g : [HW, HW] \rightarrow \text{softmax}(m)$
- $\text{feature\_map} = h \cdot m : [C_0, HW]$
- $\text{Attention} = \gamma \cdot \text{feature\_map} + x$



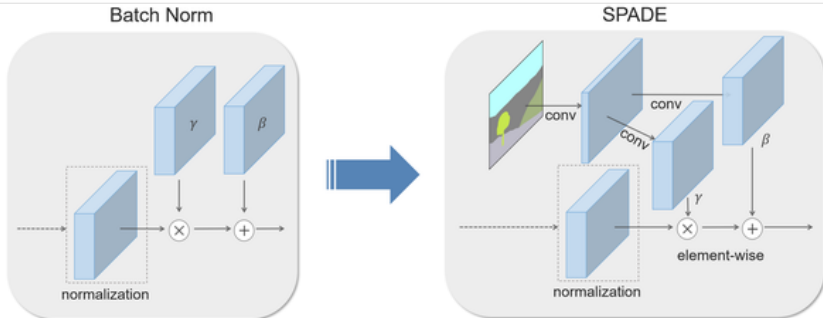
# Self-Attention для изображений



# Conditional Batch-Normalization

$$x_i \rightarrow \gamma_i \hat{x}_i + \beta_i$$

Теперь  $\gamma$  и  $\beta$  функции от  $x$






# ImageNet

GAN учится на ImageNet датасете

- Вход  $x = [z \sim P(z), \text{OneHot}(y)]$
- Генератор знает, какой класс он должен выдать
- Дискриминатор имеет полное представление о том, что на изображении



# HingeLoss


SA-GAN использует такой лосс для дискриминатора и генератора:

$$L_D = -\mathbb{E}_{(x,y) \sim p_{data}} \left[ \min(0, -1 + D(x, y)) \right] - \mathbb{E}_{z \sim p_{zy} \sim p_{data}} \left[ \min(-1 - D(G(z, y))) \right]$$

$$L_G = -\mathbb{E}_{z \sim p_{zy} \sim p_{data}} \left[ D(G(z, y)) \right]$$

# Улучшения от авторов статьи

- Вместо  $\text{OneHot}(y)$  использовать эмбединги классов.  
Таким образом можно сильно уменьшить число параметров
- $\text{OneHot}(y) \in \mathbb{R}^{1000}$ , а  $\text{Embed}(y) \in \mathbb{R}^{128}$
- "Проброс" исходной переменной  $z$  в середину сети
- Truncation Trick
- Orthogonal Regularization при отсутствии результата с Truncation Trick



# Truncation Trick

Семплируем переменную  $z$  из  $\mathbb{N}(0, I)$ . Если значение выпадает за некоторые пределы, то семплируем заново

- Приводит к улучшению всех метрик
- Уменьшает вероятность генерирования выбросов
- Но понижает вариативность



# Orthogonal Regularization

Идея в том, чтобы сделать  $G$  гладким, что все из нашего распределения имело хорошие изображения

$$R_{\beta}(W) = \beta \|WW^T - I\|_F^2$$

$W$  – матрица весов,  $\beta$  – гиперпараметр

# Orthogonal Regularization

Но это слишком сильное ограничение, поэтому авторы статьи придумали это:

$$R_{\beta}(W) = \beta \| WW^T \odot (1 - I) \|_F^2$$

Минимизирует попарное косинусное расстояние между фильтрами

# Результаты с нововведениями

Batch	Ch.	Param (M)	Shared	Skip-z	Ortho.	Itr $\times 10^3$	FID	IS
256	64	81.5	SA-GAN Baseline			1000	18.65	52.52
512	64	81.5	✗	✗	✗	1000	15.30	58.77( $\pm 1.18$ )
1024	64	81.5	✗	✗	✗	1000	14.88	63.03( $\pm 1.42$ )
2048	64	81.5	✗	✗	✗	732	12.39	76.85( $\pm 3.83$ )
2048	96	173.5	✗	✗	✗	295( $\pm 18$ )	9.54( $\pm 0.62$ )	92.98( $\pm 4.27$ )
2048	96	160.6	✓	✗	✗	185( $\pm 11$ )	9.18( $\pm 0.13$ )	94.94( $\pm 1.32$ )
2048	96	158.3	✓	✓	✗	152( $\pm 7$ )	8.73( $\pm 0.45$ )	98.76( $\pm 2.84$ )
2048	96	158.3	✓	✓	✓	165( $\pm 13$ )	8.51( $\pm 0.32$ )	99.31( $\pm 2.10$ )
2048	64	71.3	✓	✓	✓	371( $\pm 7$ )	10.48( $\pm 0.10$ )	86.90( $\pm 0.61$ )

Model	Res.	FID/IS	(min FID) / IS	FID / (valid IS)	FID / (max IS)
SN-GAN	128	27.62/36.80	N/A	N/A	N/A
SA-GAN	128	18.65/52.52	N/A	N/A	N/A
BigGAN	128	8.7 $\pm$ .6/98.8 $\pm$ 3	7.7 $\pm$ .2/126.5 $\pm$ 0	9.6 $\pm$ .4/166.3 $\pm$ 1	25 $\pm$ 2/206 $\pm$ 2
BigGAN	256	8.7 $\pm$ .1/142.3 $\pm$ 2	7.7 $\pm$ .1/178.0 $\pm$ 5	9.3 $\pm$ .3/233.1 $\pm$ 1	25 $\pm$ 5/291 $\pm$ 4
BigGAN	512	8.1/144.2	7.6/170.3	11.8/241.4	27.0/275
BigGAN-deep	128	5.7 $\pm$ .3/124.5 $\pm$ 2	6.3 $\pm$ .3/148.1 $\pm$ 4	7.4 $\pm$ .6/166.5 $\pm$ 1	25 $\pm$ 2/253 $\pm$ 11
BigGAN-deep	256	6.9 $\pm$ .2/171.4 $\pm$ 2	7.0 $\pm$ .1/202.6 $\pm$ 2	8.1 $\pm$ .1/232.5 $\pm$ 2	27 $\pm$ 8/317 $\pm$ 6
BigGAN-deep	512	7.5/152.8	7.7/181.4	11.5/241.5	39.7/298

# Картинки



Figure 5: Samples generated by our BigGAN model at  $256 \times 256$  resolution.



# Вопросы

- Как работает Conditional Batch-Normalization?
- Напишите HingeLoss для обучения генератора и дискриминатора
- Что такое Truncation Trick?